

Tarea S3.01. Introducción a BigQuery y SQL en la Nube

Contenido

Nivel 1: Entorno e Ingesta Híbrida (Code-First)	1
Ejercicio 1: Arquitectura de Datos (Lógica vs. Física)	1
Ejercicio 2: Ingesta en Capa Bronze (Conexión DDL)	3
Ejercicio 3: Carga de Datos Locales (Upload)	4
Ejercicio 4: Arquitectura y Rendimiento. Materialización de Datos (Asistido por IA)	5
Ejercicio 5: Adaptación de Sintaxis (Reporting)	8
Ejercicio 6: Consultas Complejas	9
Nivel 2	10
Ejercicio 1: Limpieza de Productos (Data Quality)	10
Ejercicio 2: Creación de Transacciones Limpias (Capa Silver)	11
Ejercicio 3: Unificación de Usuarios (UNION)	12
Ejercicio 4: Materialización de Compañías y Tarjetas de Crédito	15
Nivel 3	17
Ejercicio 1: La Vista de Marketing (Lógica de Negocio)	17
Ejercicio 2: Ranking de Productos (La Potencia de los Arrays)	18
Ejercicio 3: Exportación de Resultados	20

Nivel 1: Entorno e Ingesta Híbrida (Code-First)

Ejercicio 1: Arquitectura de Datos (Lógica vs. Física)

Antes de tocar la consola, debes entender la diferencia entre lo que diseñamos y lo que construimos:

» Arquitectura Lógica (Capas de Datos) : Es el diseño conceptual. Organiza los datos según su nivel de calidad (Bronze, Silver, Gold).

» Implementación Física (Datasets) : Es el recurso real a Google Cloud. En BigQuery, utilizaremos Datasets (contenedores) para materializar físicamente estas capas lógicas.

🔗 Tareas:

Implementará físicamente la arquitectura lógica creando tres Datasets dentro de un mismo proyecto para centralizar la facturación y los permisos.

🔗 Crea un Nuevo Proyecto en Google Cloud llamado:

sprint3-analytics-[el-teu-nom].

Puedes crearlo por la UI, pero si lo haces por Consola (gcloud CLI) tiene un plus.

Para demostrar tu dominio total de la plataforma, crearás cada uno de los datasets utilizando un método distinto:

» Dataset Físico sprint3_bronze → Capa Lógica Bronce (Datos Crudas)

Función: Datos crudos tal y como llegan de la fuente.

Método: Utiliza la Interfaz Gráfica (UI) de BigQuery (haciendo clics).

» Dataset Físico sprint3_silver → Capa Lógica Silver (Datos Limpios)

Función: Datos limpios, tipados y deduplicados.

Método: Utiliza código SQL (CREATE SCHEMA).

» Dataset Físico sprint3_gold → Capa Lógica Gold (Datos de Negocio)

Función: Datos agregados listos para informes y paneles de control (dashboards).

Método: Utiliza Cloud Shell (Línea de comandos bq).

Tenga en cuenta la ubicación de los datos originales para decidir la ubicación física de los tres Datasets.

📌 Nota : Aunque sean capas lógicas diferentes, físicamente deben vivir en la misma región para poder "hablar" entre ellas sin costes de transferencia.

Creación del proyecto con (gcloud CLI):

```
You are signed in as: [a.regueiraaraujo@gmail.com].

Pick cloud project to use:
[1] project-430b822d-a86d-4b07-94c
[2] project-792a69f3-5d57-4064-b85
[3] Enter a project ID
[4] Create a new project
Please enter numeric choice or text value (must exactly match list item): 4

Enter a Project ID. Note that a Project ID CANNOT be changed later.
Project IDs must be 6-30 characters (lowercase ASCII, digits, or
hyphens) in length and start with a lowercase letter. sprint3-analytics-alexregueira
Waiting for [operations/create_project.global.5331437112515182641] to finish...done.
Your current project has been set to: [sprint3-analytics-alexregueira].

Not setting default zone/region (this feature makes it easier to use
[gcloud compute] by setting an appropriate default value for the
--zone and --region flag).
See https://cloud.google.com/compute/docs/gcloud-compute section on how to set
default compute region and zone manually. If you would like [gcloud init] to be
able to do this for you the next time you run it, make sure the
Compute Engine API is enabled for your project on the
https://console.developers.google.com/apis page.

Created a default .boto configuration file at [C:\Users\alexa\.boto]. See this file and
[https://cloud.google.com/storage/docs/gsutil/commands/config] for more
information about configuring Google Cloud Storage.
The Google Cloud CLI is configured and ready to use!
```

Creación del database sprint3_bronze:

The screenshot shows the Google Cloud Platform console for the project 'sprint3-analytics-alexregueira'. The 'Datasets' section is active, showing a table with one dataset named 'sprint3_bronze'. The table has columns for 'ID de tabla', 'Tipo', 'Fecha de creación', 'Hora de vencimiento', and 'Etiqueta'. The 'sprint3_bronze' dataset is listed with a type of 'Table' and a creation date of '2023-09-14 10:10:10'. The 'Descripción general' tab is selected, showing a description of the dataset.


Creación del database sprint3_silver

The screenshot shows the Google Cloud Platform console for the project 'sprint3-analytics-alexregueira'. The 'Datasets' section is active, showing a table with one dataset named 'sprint3_silver'. The table has columns for 'ID de tabla', 'Tipo', 'Fecha de creación', 'Hora de vencimiento', and 'Etiqueta'. The 'sprint3_silver' dataset is listed with a type of 'Table' and a creation date of '2023-09-14 10:10:10'. The 'Descripción general' tab is selected, showing a description of the dataset.

Creación del database Sprint3_gold

```
Welcome to Cloud Shell! Type "help" to get started, or type "gemini" to try prompting with Gemini CLI.
Your Cloud Platform project in this session is set to sprint3-analytics-alexregueira.
Use 'gcloud config set project [PROJECT_ID]' to change to a different project.
a_regueiraaraujo@cloudshell:~ (sprint3-analytics-alexregueira)$ bq mk --dataset --location=EU sprint3-analytics-alexregueira:sprint3_gold
Dataset 'sprint3-analytics-alexregueira:sprint3_gold' successfully created.
```

Databases creados:



ID de conjunto de datos	Fuente	Tipo	Ubicación	Fecha de creación	Etiqueta	
sprint3_bronze	BigQuery	Default	EU		Ninguno	⋮ ☆
sprint3_gold	BigQuery	Default	EU		Ninguno	⋮ ☆
sprint3_silver	BigQuery	Default	EU		Ninguno	⋮ ☆

Ejercicio 2: Ingesta en Capa Bronze (Conexión DDL)

Un analista profesional automatiza las labores. Ahora que tienes tu arquitectura a punto, poblaremos la primera capa (**Bronze**) sin mover los datos originales, creando **Tablas Externas** que apunten al Data Lake.


🔧 Tarea:

Escribe y ejecuta las sentencias CREATE EXTERNAL TABLE para conectar los siguientes archivos al *dataset* **sprint3_bronze** . Presta mucha atención a las "Notas Técnicas", ya que no todos los archivos tienen el mismo formato.

📌 Entrega:


El código SQL utilizado para transactions_rawy una captura de pantalla con las 5 tablas creadas.

Creación de la tabla transactions_raw:



```
1 CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-alexregueira.sprint3_bronze.transactions_raw`
2 OPTIONS (
3   format = 'CSV',
4   uris = ['gs://bootcamp-data-analytics-public/ERP/transactions.csv'],
5   field_delimiter = ';',
6   skip_leading_rows = 1
7 );
```

Tablas creadas:




ID de tabla	Tipo	Fecha de creación	Hora de vencimiento	Etiqueta	
american_users_raw	Tabla	12 jul 2026, 8:13:20p.m. UTC+2	10 sept 2026, 8:13:20p.m. UTC+2	Ninguno	⋮ ☆
companies_raw	Tabla	12 jul 2026, 8:14:41 p.m. UTC+2	10 sept 2026, 8:14:41 p.m. UTC+2	Ninguno	⋮ ☆
credit_cards_raw	Tabla	12 jul 2026, 8:13:23p.m. UTC+2	10 sept 2026, 8:13:23p.m. UTC+2	Ninguno	⋮ ☆
european_users_raw	Tabla	12 jul 2026, 8:13:21 p.m. UTC+2	10 sept 2026, 8:13:21 p.m. UTC+2	Ninguno	⋮ ☆
transactions_raw	Tabla	12 jul 2026, 8:09:49p.m. UTC+2	10 sept 2026, 8:09:49p.m. UTC+2	Ninguno	⋮ ☆

Ejercicio 3: Carga de Datos Locales (Upload)

Falta el catálogo de **Productos** . Esta información no está en Data Lake, utiliza el archivo *products.csv* del sprint 2.

- » Carga este archivo manualmente ("Upload") en el dataset sprint3_bronzey crea la tabla *products_raw*.
- » Observa que ésta será la única **Mesa Nativa** de momento.

Datos cargados desde el ordenador.



sprint3-analytics-alexregueira / Datasets / sprint3_bronze					
☆ sprint3_bronze		+ Crear tabla	Chatear	Vista previa	+ Compartir
Descripción general Detalles Estadísticas Vista previa					
Tablas Grafos Modelos Rutinas					
Filtro Escribir el nombre o valor de la propiedad					
ID de tabla	Tipo	Fecha de creación	Hora de vencimiento	Etiqueta	
american_users_raw	Tabla	12 jul 2026, 8:13:20 p.m. UTC+2	10 sept 2026, 8:13:20 p.m. UTC+2	Ninguno	⋮ ☆
companies_raw	Tabla	12 jul 2026, 8:14:41 p.m. UTC+2	10 sept 2026, 8:14:41 p.m. UTC+2	Ninguno	⋮ ☆
credit_cards_raw	Tabla	12 jul 2026, 8:13:23 p.m. UTC+2	10 sept 2026, 8:13:23 p.m. UTC+2	Ninguno	⋮ ☆
european_users_raw	Tabla	12 jul 2026, 8:13:21 p.m. UTC+2	10 sept 2026, 8:13:21 p.m. UTC+2	Ninguno	⋮ ☆
products_raw	Tabla	12 jul 2026, 11:28:44 p.m. UTC+2	10 sept 2026, 11:28:44 p.m. UTC+2	Ninguno	⋮ ☆
transactions_raw	Tabla	12 jul 2026, 8:09:49 p.m. UTC+2	10 sept 2026, 8:09:49 p.m. UTC+2	Ninguno	⋮ ☆

Ejercicio 4: Arquitectura y Rendimiento. Materialización de Datos (Asistido por IA)

Escenario:

Las consultas sobre el Data Lake van lentas. Tienes que demostrar a tu manager la diferencia de rendimiento entre trabajar con archivos externos y trabajar con tablas nativas de BigQuery.

a) Materialización de Datos (Asistido por IA)

Tarea:

Crea una tabla nueva llamada `sprint3_bronze.transactions_raw_native` que sea una copia exacta de tu tabla externa `transactions_raw`.

Requisito de "AI-Pair Programming":

No escribas el código SQL manualmente. Utiliza el Asistente de IA (Gemini) integrado en BigQuery (o el chat lateral) para generar la sentencia.

 **Tu Rol** : Eres el responsable de validar que el código que te da la IA es correcto antes de ejecutarlo.


Prompt Sugerido:

"Write a SQL query to create a new table called `transactions_raw_native` in the `sprint3_bronze` dataset. It should contain all data from the `transactions_raw` table. Please use `CREATE OR REPLACE TABLE` so I don't get errors if I run it more than once."

Entrega:

Una captura de pantalla donde se vea:

- » El prompt que escribiste en la IA.
- » El código SQL que la IA va a generar.
- » El resultado de la ejecución ("This statement created a new table...").



b) Auditoría de Costes:

Sin LIMIT;

Tarea:


Diseñar una prueba para comparar el coste de leer una sola columna (ej: id) en la tabla externa vs. la mesa nativa. Utiliza los Bytes procesados y los Bytes facturados para realizar la comparación.

- » ¿Cuánto "pesa" la consulta en transactions_raw?
- » ¿Cuánto "pesa" la misma consulta en transactions_raw_native?

Entrega:

Capturas del validador mostrando la diferencia y una conclusión técnica.


Consulta de la columna id de la tabla transactions_raw_native.



The screenshot shows a Databricks query interface. The query is: `SELECT id FROM `sprint3-analytics-alexregueira.sprint3_bronze.transactions_raw_native`;`. The execution details show that the query will process 3.62 MB and bill 10 MB.

Job information	Results	Visualization	JSON	Execution details
Bytes processed	3.62 MB			
Bytes billed	10 MB			

Consulta de la columna id de la tabla transactions_raw.



The screenshot shows a Databricks query interface. The query is: `SELECT id FROM `sprint3-analytics-alexregueira.sprint3_bronze.transactions_raw`;`. The execution details show that the query will process 0 B and bill 13 MB.

Job information	Results	Visualization	JSON	Execution details
Bytes processed	12.61 MB			
Bytes billed	13 MB			

La tabla nativa permite aprovechar el almacenamiento columnar, leyendo únicamente los datos necesarios para esa columna específica, lo que garantiza un control de costes mucho más preciso que el uso de tablas externas

C) El peligro del LIMIT

Con LIMIT 10;


¿LIMITE ahorra datos procesados en BIGQUERY?

Tarea:

Fes un **LIMIT 10** sobre la taula transactions_raw_native y la taula transactions_raw

☒ **Comprobación** : Mira el "Dry Run". ¿Ha bajado el coste respecto a no poner LIMIT?
Explica brevemente por qué esto es una trampa para principiantes.

Con LIMIT 10:



The image shows two screenshots of the BigQuery interface. The top screenshot shows a query: `SELECT * FROM `sprint3-analytics-alexregueira.sprint3_bronze.transactions_raw` LIMIT 10;`. The status bar indicates "Esta consulta procesará 0 B cuando se ejecute." (This query will process 0 B when executed). The "Resultados de la consulta" (Query Results) table shows:

Información del trabajo	Resultados	Visualización	JSON	Detalles de la ejecución
Bytes procesados	Undefined parameter - BYTES_CONTAINER (resultados almacenados en caché)			
Bytes facturados	0 B			

The bottom screenshot shows the same query but for the table `transactions_raw_native`. The status bar indicates "Se completó la consulta" (Query completed). The "Resultados de la consulta" table shows:`

Información del trabajo	Resultados	Visualización	JSON	Detalles de la ejecución
Bytes procesados	10.87 MB			
Bytes facturados	11 MB			

El LIMIT no reduce el coste en BigQuery, ya que el motor escanea todas las filas y columnas antes de aplicar el recorte final, devolviendo solo las primeras N filas del resultado, no de la lectura. Por eso el Dry Run mostró el mismo coste con y sin LIMIT.


Ejercicio 5: Adaptación de Sintaxis (Reporting)

Tu jefe quiere saber cuáles fueron los 5 días con mayores ingresos del año 2021 .

 Reto:

Probablemente el campo timestamp es un STRING. Tendrás que investigar funciones de BigQuery (SUBSTR, CAST, PARSE_TIMESTAMP) para filtrar el año y agrupar por fecha correctamente

Los 5 días con mayores ingresos del año 2021:



The screenshot shows the Google Cloud BigQuery console interface. At the top, there's a toolbar with 'Run', 'Save', 'Schedule', and 'Share' buttons. Below the toolbar is a menu with 'File', 'Edit', 'Run', and 'Tools'. The main area displays a SQL query:

```
1 SELECT CAST(timestamp AS DATE) AS date, ROUND(SUM(amount),2) AS total_amount
2 FROM `sprint3-analytics-alexregueira.sprint3_bronze.transactions_raw`
3 WHERE timestamp IN (SELECT timestamp
4 FROM `sprint3-analytics-alexregueira.sprint3_bronze.transactions_raw`
5 WHERE EXTRACT (YEAR FROM timestamp) = 2021
6 ORDER BY DATE(timestamp))
7 GROUP BY CAST(timestamp AS DATE)
8 ORDER BY total_amount DESC
9 LIMIT 5;
```

Below the query, a green checkmark indicates 'Query completed'. The processing location is 'EU'. The 'Query results' section is expanded, showing a table with 5 rows of data. The table has columns 'date' and 'total_amount'.

Row	date	total_amount
1	2021-10-27	11440.81
2	2021-01-22	11328.84
3	2021-02-11	11182.16
4	2021-04-29	11119.01
5	2021-03-27	10898.51

Ejercicio 6: Consultas Complejas

Necesitamos un informe que cruce datos.

 Tarea:

Lista el nombre, país y fecha de las transacciones realizadas por empresas que realizaron operaciones entre 100 y 200 euros en alguna de estas fechas: 29-04-2015, 20-07-2018 o 13-03-2024.

Se realizó un JOIN entre las tablas de compañías y transacciones para cruzar los datos, filtrando por rango de importe y por las tres fechas específicas solicitadas, obteniendo así el informe combinado requerido.

```
1 SELECT co.company_name, co.country, DATE(t.timestamp), t.amount
2 FROM `sprint3-analytics-alexregueira.sprint3_bronze.companies_raw` AS co
3 JOIN `sprint3-analytics-alexregueira.sprint3_bronze.transactions_raw` AS t
4 ON t.business_id = co.company_id
5 WHERE t.amount > 100 AND t.amount <200 AND (
6 DATE (timestamp) IN ('2015-04-29', '2018-07-20', '2024-03-13'))
7 ORDER BY amount;
```

Query completed

Processing location: EU No cached results

>I Query results Chat

Job informationResultsVisualizationJSONExecution detailsExecution graph

Row	company_name	country	f0_	amount
1	Netus Et Malesuada Ltd	Netherlands	2018-07-20	103.73
2	Justo Eu Arcu Ltd	Italy	2024-03-13	114.09
3	Et Magnis Ltd	Belgium	2018-07-20	114.44
4	Fusce Corp.	United States	2018-07-20	114.77
5	At Pede Corp.	Italy	2018-07-20	115.16
6	Ac Libero Inc.	United Kingdom	2015-04-29	124.04
7	Tempor Diam Institute	Netherlands	2018-07-20	124.04
8	Tempor Diam Institute	Netherlands	2018-07-20	124.04
9	Aliquam Erat Volutpat LLP	Italy	2018-07-20	127.09
10	Aliquam Erat Volutpat LLP	Italy	2024-03-13	128.48


Nivel 2

Ejercicio 1: Limpieza de Productos (Data Quality)

Crearemos la capa limpia ("Silver") para los productos. Tienes la mesa `sprint3_bronze.products_raw` cargada desde el CSV. El equipo de Data Governance te pide crear una mesa de productos limpia a `sprint3_silver.products_clean` que cumpla estas reglas de calidad:

- **» Estandarización de Nombres** : La columna original `id` es ambigua; renombrarla a `product_id`. La columna `product_name` simplifícala a `name`.
- **» Limpieza de IDs** : El campo `warehouse_id` tiene el formato antiguo "WH-4". Elimina el prefijo "WH-" y convierte el valor en número entero (INT64).
- **» Garantía de Precio** : Asegúrate de que `price` es un número (FLOAT64), sin símbolos de moneda.
- **» Demás columnas** : Conserva el campo `weight` (peso) tal cual.

Se estandarizaron los nombres de columnas, se limpió el prefijo "WH-" del `warehouse_id` convirtiéndolo a INT64, y se garantizó que `price` fuera FLOAT64, cumpliendo así las reglas de calidad de la capa Silver.



```
1 CREATE OR REPLACE TABLE `sprint3-analytics-alexregueira.sprint3_silver.products_clean` AS
2 SELECT
3   id AS product_id,
4   product_name AS name,
5   colour AS colour,
6   brand AS brand,
7   category AS category,
8   launch_date AS launch_date,
9   weight AS weight,
10  CAST(REPLACE(warehouse_id, 'WH-', '') AS INT64) AS warehouse_id,
11  CAST(price AS FLOAT64) AS price
12 FROM `sprint3-analytics-alexregueira.sprint3_bronze.products_raw`;
13
14 |
15 SELECT column_name, data_type
16 FROM `sprint3-analytics-alexregueira.sprint3_silver`.INFORMATION_SCHEMA.COLUMNS
17 WHERE table_name = 'products_clean'
18 ORDER BY ordinal_position;
19
20
21 SELECT * FROM `sprint3-analytics-alexregueira.sprint3_silver.products_clean`
22 LIMIT 10
23
```

✓ This script will process 8.1 KB when run.

Using on-demand processing quota Processing location: EU ✕

Query results

Job information		Results	Visualization	JSON	Execution details		Execution graph		
Row	product_id	name	colour	brand	category	launch_date	weight	warehouse_id	price
1	48	rock Renly in	#9e9e9e	Bloom	Beauty	2014-07-24	2.1	43	21.53
2	96	dooku solo	#282828	CareLab	Beauty	2013-09-21	2.1	91	20.92
3	18	Karstark warden	#c4c4c4	CareLab	Beauty	2013-07-11	0.8	13	148.91
4	97	jinn Winterfell	#bababa	CareLab	Beauty	2013-02-22	1.0	92	65.25
5	90	Winterfell	#757575	CareLab	Beauty	2013-11-01	0.8	85	39.73

Row	column_name	data_type
1	product_id	INT64
2	name	STRING
3	colour	STRING
4	brand	STRING
5	category	STRING
6	launch_date	DATE
7	weight	FLOAT64
8	warehouse_id	INT64
9	price	FLOAT64

Ejercicio 2: Creación de Transacciones Limpias (Capa Silver)

Escenario:

La tabla `transactions_raw` (Bronze) es insegura: el importe (`amount`) podría tener letras, las coordenadas podrían fallar y la fecha es un texto difícil de filtrar. Crearemos la mesa definitiva `sprint3_silver.transactions_clean` que garantice lo siguiente.

- » Estandarización de Nombres : La columna original `id` es ambigua; renombrarla a `transaction_id`.
- » Robustez en Importes : Utiliza `SAFE_CAST` en el campo `amount`. Si falla, sustitúyelo por 0 (usando `IFNULL`).
- » Fechas Reales : Convierte el campo `timestamp` (que es `STRING`) a tipo `TIMESTAMP` real.
- » Coordenadas : Asegura que `lat` y `longitud` sean `FLOAT64` (utiliza `SAFE_CAST` para seguridad).
- » Desglose de Productos: Transforma la cadena de texto `product_ids` en un `ARRAY` de enteros .

Input: "1, 2, 3" (String)

Output: [1, 2, 3] (Array/Lista de enteros)

- » Resto de campos : Manténlos igual.

El uso de `SAFE_CAST` combinado con `IFNULL` garantiza que la tabla nunca falle por datos corruptos, sustituyendo los valores no convertibles por 0 en lugar de generar un error. Además, se transformó el `timestamp` de texto a tipo `TIMESTAMP` real y se desglosó `product_ids` en un array de enteros mediante `SPLIT` y `UNNEST`.

```

1 CREATE OR REPLACE TABLE `sprint3-analytics-alexregueira.sprint3_silver.transactions_clean` AS
2 SELECT
3   id AS transaction_id,
4   card_id,
5   business_id,
6   SAFE_CAST(timestamp AS TIMESTAMP) AS timestamp,
7   IFNULL(SAFE_CAST(amount AS FLOAT64), 0) AS amount,
8   declined,
9   ARRAY(
10     SELECT CAST(TRIM(x) AS INT64)
11     FROM UNNEST(SPLIT(product_ids, ',')) AS x
12   ) AS product_ids,
13   user_id,
14   SAFE_CAST(lat AS FLOAT64) AS lat,
15   SAFE_CAST(longitude AS FLOAT64) AS longitude
16 FROM `sprint3-analytics-alexregueira.sprint3_bronze.transactions_raw`;

```

✓ Se completó la consulta

Ubicación de procesamiento: EU ✕

>I Resultados de la consulta [Chat](#) [View all jobs](#)

Información del trabajo **Resultados** Detalles de la ejecución Gráfico de ejecución

i Esta declaración creó una nueva tabla con el nombre transactions_clean.

```

1 SELECT transaction_id, timestamp, amount, product_ids, lat, longitude
2 FROM `sprint3-analytics-alexregueira.sprint3_silver.transactions_clean`
3 LIMIT 10;

```

✓ Se completó la consulta

Se está usando la cuota de procesamiento según demanda Ubicación de procesamiento: EU ✕

>I Resultados de la consulta [Chat](#) [View all jobs](#) [Guardar los resultados](#)

Información del trabajo **Resultados** Visualización JSON Detalles de la ejecución Gráfico de ejecución

Fila	transaction_id	timestamp	amount	product_ids	lat	longitude
1	3F2720A9-C1C9-4D9B-9FFD-C8...	2020-08-20 16:55:54 UTC	189.72	81	40.71327173022...	-74.00448266281...
				94		
				65		
2	78C7704E-F5D1-460C-95BF-DB...	2020-11-02 01:02:53 UTC	294.36	99	40.71648153340...	-74.01193026852...
				80		
				34		
3	78F14A51-F321-4CA9-AB42-02...	2018-10-24 09:46:13 UTC	265.14	17	40.70368041705...	-74.00801396198...
				66		
				3		

Ejercicio 3: Unificación de Usuarios (UNION)

Tenemos a los usuarios fragmentados por región.

Tarea:

Crea la mesa sprint3_silver.users_combined. Utiliza UNION ALL para unificar a los usuarios de EE.UU. y Europa en una única lista maestra. Añade una columna calculada origen para saber de dónde vienen.

- » **Estandarización de Nombres** : La columna original id es ambigua; renombrarla a user_id.

Se unificaron los usuarios de ambas regiones mediante UNION ALL, ya que las tablas de origen no tenían duplicados entre sí, añadiendo la columna origen para poder identificar la procedencia de cada usuario tras la unificación.

1 SELECT user_id, name, country, origin

2 FROM `sprint3-analytics-alexregueira.sprint3\_silver.users\_combined`

3 LIMIT 10;

Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Ubicación de procesamiento: EU

>I Resultados de la consulta

Chat

View all

Información del trabajo

Resultados

Visualización

JSON

Detalles de la ejecución

Fila	user_id	name	country	origin
1	272	Hedwig	Canada	EE.UU.
2	520	Qdunsj	Canada	EE.UU.
3	3414	Phunkw	Canada	EE.UU.
4	203	Jarrood	Canada	EE.UU.
5	3932	Amhiar	Canada	EE.UU.
6	1772	Rysxpj	Canada	EE.UU.
7	1405	Chjqfw	Canada	EE.UU.
8	2013	Erswn	Canada	EE.UU.
9	4438	Wypaxn	Canada	EE.UU.
10	3239	Fwsdlr	Canada	EE.UU.

```

1 CREATE OR REPLACE TABLE `sprint3-analytics-alexregueira.sprint3_silver.users_combined` AS
2 SELECT
3   id AS user_id,
4   name,
5   surname,
6   phone,
7   email,
8   birth_date,
9   country,
10  city,
11  postal_code,
12  address,
13  'EE.UU.' AS origin
14 FROM `sprint3-analytics-alexregueira.sprint3_bronze.american_users_raw`
15
16 UNION ALL
17
18 SELECT
19   id AS user_id,
20   name,
21   surname,
22   phone,
23   email,
24   birth_date,
25   country,
26   city,
27   postal_code,
28   address,
29   'Europa' AS origin
30 FROM `sprint3-analytics-alexregueira.sprint3_bronze.european_users_raw`;

```

✓ Se completó la consulta

Ubicación de procesamiento: EU ✕

>I Resultados de la consulta

Chat

View all jobs

Información del trabajo

Resultados

Detalles de la ejecución

Gráfico de ejecución

❗ Esta declaración creó una nueva tabla con el nombre users_combined.

```

1 SELECT origin, COUNT(*) AS total
2 FROM `sprint3-analytics-alexregueira.sprint3_silver.users_combined`
3 GROUP BY origin;

```

✓ Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Ubicación de procesamiento: EU ✕

>I Resultados de la consulta

Información del trabajo

Resultados

Visualización

JSON

Detalles

Fila	origin	total
1	EE.UU.	1010
2	Europa	3990

Ejercicio 4: Materialización de Compañías y Tarjetas de Crédito

Escenario:

Para completar el modelo de datos en la capa Silver, nos faltan dos dimensiones clave que actualmente dependen de archivos CSV externos: **Compañías y Tarjetas de Crédito**. No podemos depender de archivos sueltos para el análisis final. Debemos importar estos datos en tablas nativas (Silver) y aprovechar para corregir formatos.

Tareas:

» 1. Crea la tabla `sprint3_silver.companies_clean`. Copia los datos tal cual, pero asegúrate de que sea una tabla nativa de BigQuery (no una vista externa).

» 2. Crea la tabla `sprint3_silver.credit_cards_clean`. Copia los datos tal cual, pero asegúrate de que sea una tabla nativa de BigQuery (no una vista externa).

Si es necesario, renombrar el id según corresponda.

Se materializaron ambas dimensiones como tablas nativas mediante `CREATE TABLE AS SELECT` (CTAS), eliminando la dependencia de archivos CSV externos y garantizando un acceso más rápido y consistente a estos datos de referencia.

Creación de la tabla `companies_clean` en la capa Silver.

```
1 CREATE OR REPLACE TABLE `sprint3-analytics-alexregueira.sprint3_silver.companies_clean` AS
2 SELECT *
3 FROM `sprint3-analytics-alexregueira.sprint3_bronze.companies_raw`;
```

✓ Se completó la consulta

Ubicación de procesamiento: EU ✕

>I Resultados de la consulta Chat View all jobs

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

i Esta declaración creó una nueva tabla con el nombre `companies_clean`.

Creación de la tabla `credit_cards_clean` en la capa Silver.

```
1 CREATE OR REPLACE TABLE `sprint3-analytics-alexregueira.sprint3_silver.credit_cards_clean` AS
2 SELECT
3   id AS card_id,
4   user_id,
5   iban,
6   pan,
7   pin,
8   cvv,
9   track1,
10  track2,
11  expiring_date
12 FROM `sprint3-analytics-alexregueira.sprint3_bronze.credit_cards_raw`;
```

✓ Se completó la consulta

Ubicación de procesamiento: EU ✕

>I Resultados de la consulta Chat View all jobs

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

i Esta declaración creó una nueva tabla con el nombre `credit_cards_clean`.

Comprobación del tipo de tabla.

Consulta sin título Ejecutar Guardar Programa Compartir

Archivo Editar Ejecutar Herramientas

```
1 SELECT table_name, table_type
2 FROM `sprint3-analytics-alexregueira.sprint3_silver`.INFORMATION_SCHEMA.TABLES
3 WHERE table_name IN ('companies_clean', 'credit_cards_clean');
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda Ubicación de procesamiento:

>I Resultados de la consulta Chat

Información del trabajo Resultados Visualización JSON Detalles de la ejecución

Fila	table_name	table_type
1	credit_cards_clean	BASE TABLE
2	companies_clean	BASE TABLE

Comprobación de los elementos de la tabla companies_clean.

Consulta sin título Ejecutar Guardar Programa Compartir

Archivo Editar Ejecutar Herramientas

```
1 SELECT *
2 FROM `sprint3-analytics-alexregueira.sprint3_silver`.companies_clean
3 LIMIT 5;
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda Ubicación de procesamiento: EU X

>I Resultados de la consulta Chat View all jobs Guardar los resultados

Información del trabajo Resultados Visualización JSON Detalles de la ejecución Gráfico de ejecución

Fila	company_id	company_name	phone	email	country	website
1	b-2282	Pretium Neque Corp.	07 77 48 55 28	eleifend.nec.malesuada@protonmail.cook	Australia	https://netflix.com/sub
2	b-2498	Metus Vitae Associates	08 25 44 40 66	ad@protonmail.com	Australia	https://google.com/site
3	b-2226	Magna A Neque Industries	04 14 44 64 62	rius.donec.nibh@icloud.org	Australia	https://whatsapp.com/group/9
4	b-2446	Risus Associates	04 25 82 54 31	egestas.ligula.nullam@google.edu	Australia	https://whatsapp.com/group/9
5	b-2334	Amet Institute	06 33 40 21 33	nullam.lobortis.quam@outlook.net	Australia	https://nytimes.com/one

Comprobación de los elementos de la tabla credit_cards_clean.

```
1 SELECT card_id, user_id, iban, expiring_date
2 FROM `sprint3-analytics-alexregueira.sprint3_silver`.credit_cards_clean
3 LIMIT 5;
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda Ubicación de procesamiento: EU X

>I Resultados de la consulta Chat View all jobs

Información del trabajo Resultados Visualización JSON Detalles de la ejecución

Fila	card_id	user_id	iban	expiring_date
1	CcU-3925	134	NL40SLES4851032267	2020-03-18
2	CcU-4618	35	CY40326276160678118750340...	2020-03-24
3	CcU-3666	171	DE35385647561242046858	2020-03-26
4	CcU-4226	91	CR7348306166727297113	2020-04-13
5	CcU-3645	174	PS77497227364829573541665...	2020-04-17

Nivel 3

Ejercicio 1: La Vista de Marketing (Lógica de Negocio)

Marketing necesita segmentar a los clientes corporativos, pero no saben hacer JOINS. Su tarea es dejarles la información preparada.

Tarea:

Crea una vista llamada `sprint3_gold.v_marketing_kpis` que muestre la siguiente información para cada compañía:

- » **Nombre de la compañía, Teléfono y País** (origen: `companies_clean`).
- » **Media de compra** (AVG(amount) de `transactions_clean`).
- » **Clasificación de Cliente (Lógica) :**
 - Crea una columna calculada llamada `client_tier`.
 - Si la media de compra es superior a **260 €**, etiqueta como **"Premium"**.
 - Si es igual o inferior, etiqueta como **"Standard"**.

Entrega:

Realiza una consulta SELECT *sobre tu nueva vista, ordenando los resultados para que aparezcan primero los clientes "Premium" y, dentro de éstos, los que tengan mayor promedio de compra.

La vista `v_marketing_kpis` encapsula la lógica de negocio (JOIN, promedio y clasificación) en un objeto reutilizable, permitiendo que el equipo de Marketing consulte los datos ya preparados sin necesidad de escribir SQL complejo.

```
1 CREATE OR REPLACE VIEW `sprint3-analytics-alexregueira.sprint3_gold.v_marketing_kpis` AS
2 SELECT
3   co.company_name,
4   co.phone,
5   co.country,
6   AVG(t.amount) AS avg_purchase,
7   CASE
8     WHEN AVG(t.amount) > 260 THEN 'Premium'
9     ELSE 'Standard'
10  END AS client_tier
11 FROM `sprint3-analytics-alexregueira.sprint3_silver.companies_clean` AS co
12 JOIN `sprint3-analytics-alexregueira.sprint3_silver.transactions_clean` AS t
13   ON t.business_id = co.company_id
14 GROUP BY co.company_name, co.phone, co.country;
```

Se completó la consulta

Ubicación de procesamiento: EU

Resultados de la consulta

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

Esta declaración creó una nueva vista llamada `v_marketing_kpis`.

```

1 SELECT *
2 FROM `sprint3-analytics-alexregueira.sprint3_gold.v_marketing_kpis`
3 ORDER BY
4     CASE WHEN client_tier = 'Premium' THEN 0 ELSE 1 END,
5     avg_purchase DESC;

```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda Ubicación de procesamiento: EU

Resultados de la consulta

Información del trabajo	Resultados	Visualización	JSON	Detalles de la ejecución	Gráfico de ejecución
Fila	company_name	phone	country	avg_purchase	client_tier
1	Ac Fermentum Incorporated	06 85 56 52 33	Germany	284.8671595168...	Premium
2	Pretium Neque Corp.	07 77 48 55 28	Australia	276.1583295711...	Premium
3	Urna Convallis Associates	06 01 24 77 04	United States	274.2350109409...	Premium
4	At Associates	09 56 61 10 65	New Zealand	272.2148701298...	Premium
5	Metus Vitae Associates	08 25 44 40 66	Australia	270.0809647058...	Premium
6	Aliquet Diam Limited	02 76 61 47 46	United States	269.5991810344...	Premium
7	Nec Luctus LLC	02 14 71 75 73	Norway	268.6048370927...	Premium
8	Neque Tellus Incorporated	04 43 18 34 19	Ireland	267.8503720930...	Premium
9	Tortor Nunc Commodore Company	05 35 92 77 16	United States	267.8360851063...	Premium
10	Cras Consulting	07 50 10 85 63	Belgium	267.4394092827...	Premium

Ejercicio 2: Ranking de Productos (La Potencia de los Arrays)

Escenario de Negocio:

El equipo de ventas desea optimizar el catálogo. Necesitan un informe en la capa Gold que muestre el rendimiento real de cada producto. Gracias a tu buena ingeniería en la capa Silver, la mesa `transactions_clean` ya tiene los IDs de producto perfectamente organizados en una lista (Array). Ahora toca explotar esa estructura.

Objetivo:

Crea la tabla `sprint3_gold.product_sales_ranking` que contenga el inventario completo de productos y cuántas veces se ha vendido cada uno.

Requisitos del Informe:

- » **Detalle del Producto** : Debe incluir `product_id`, `name`, `price` y `color` (vienen de la tabla `products_clean`).
- » **Métrica de Negocio** : Una columna nueva `total_sold` que cuente cuántas veces aparece este producto en las transacciones.
- » **Integridad** : Deben aparecer todos los productos, incluso los que tienen 0 ventas (quizás es necesario descatalogarlos).

Pista Técnica:

- » En `transactions_clean`, los productos están "encapsulados" dentro de un Array por cada transacción.
- » Primero necesitarás "allanar" la tabla de transacciones usando `UNNEST(product_ids)` para poder contar los productos individualmente.
- » Después, haz un cruce (`LEFT JOIN`) empezando por la mesa de productos para no perder aquellos que nunca se han vendido.

Se utilizó UNNEST para "aplanar" el array product_ids y poder contar las apariciones de cada producto, y un LEFT JOIN desde products_clean para asegurar que todos los productos aparecieran en el informe, incluso aquellos sin ventas registradas.

```

1 CREATE OR REPLACE TABLE `sprint3-analytics-alexregueira.sprint3_gold.product_sales_ranking` AS
2 WITH product_sales AS (
3   SELECT product_id_sold, COUNT(*) AS total_sold
4   FROM `sprint3-analytics-alexregueira.sprint3_silver.transactions_clean`,
5   UNNEST(product_ids) AS product_id_sold
6   GROUP BY product_id_sold
7 )
8 SELECT
9   p.product_id,
10  p.name,
11  p.price,
12  p.colour,
13  IFNULL(ps.total_sold, 0) AS total_sold
14 FROM `sprint3-analytics-alexregueira.sprint3_silver.products_clean` AS p
15 LEFT JOIN product_sales AS ps
16   ON p.product_id = ps.product_id_sold
17 ORDER BY total_sold DESC;

```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda Ubicación de procesamiento: EU

>I Resultados de la consulta Chat View all jobs

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

Esta declaración creó una nueva tabla con el nombre product_sales_ranking.

```

1 SELECT *
2 FROM `sprint3-analytics-alexregueira.sprint3_gold.product_sales_ranking`
3 ORDER BY total_sold DESC
4 LIMIT 10;

```

Se completó la consulta

Ubicación de procesamiento: EU

>I Resultados de la consulta Chat View all jobs Guardar los

Información del trabajo Resultados Visualización JSON Detalles de la ejecución Gráfico de ejecución

Fila	product_id	name	price	colour	total_sold
1	52	riverlands the duel	31.52	#727272	2654
2	29	Tully maester Tarly	167.2	#111111	2635
3	21	duel Direwolf	96.9	#e2e2e2	2609
4	16	the duel warden	180.91	#666666	2608
5	66	mustafar jinn	2.12	#545454	2601
6	87	sith Jade	96.26	#e2e2e2	2598
7	33	duel warden	127.09	#191919	2597
8	48	rock Renly in	21.53	#9e9e9e	2597
9	23	riverlands north	169.96	#545454	2593
10	68	Stark Karstark	167.37	#333333	2589

```

1 SELECT COUNT(*) AS productos_sin_venta
2 FROM `sprint3-analytics-alexregueira.sprint3_gold.product_sales_ranking`
3 WHERE total_sold = 0;

```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda Ubicación de procesamiento: EU

>I Resultados de la consulta Chat View all jobs Guardar los

Información del trabajo Resultados Visualización JSON Detalles de la ejecución

Fila	productos_sin_venta
1	0

Ejercicio 3: Exportación de Resultados

Tu manager no tiene acceso a BigQuery y quiere el listado de "Top Productos" en un Excel para una reunión.

Tarea:

Exporta los datos de la tabla `product_sales_ranking` a **Google Sheets** o descarga el archivo **CSV** localmente.

Entrega:

Una captura de pantalla donde se vea el archivo abierto (Excel/Sheets) con los datos correctamente formateados.

Exportación de la tabla a csv.

The screenshot shows the Google Cloud BigQuery console. At the top, there's a query editor with the text: `SELECT * FROM `sprint3-analytics-alexrequeira.sprint3_gold.product_sales_ranking` ;`. Below the editor, a status bar indicates "Query completed" and "Using on-demand processing quota". To the right of the query editor, a dropdown menu is open, showing export options: "Google Drive", "CSV up to 1GB", "JSONL (newline delimited) up to 1GB", "Google Sheets up to 10MB", "Local download", "CSV up to 10MB" (highlighted with a red circle), "JSON up to 10MB", "Google Cloud", "Cloud Storage", and "BigQuery table". Below the menu, the "Query results" tab is active, displaying a table with 9 rows of data. The table has columns: Row, product_id, name, price, colour, and total_sold.

Row	product_id	name	price	colour	total_sold
1	52	riverlands the duel	31.52	#727272	2654
2	29	Tully maester Tarly	167.2	#111111	2635
3	21	duel Direwolf	96.9	#e2e2e2	2609
4	16	the duel warden	180.91	#666666	2608
5	66	mustafar jinn	2.12	#545454	2601
6	87	sith Jade	96.26	#e2e2e2	2598
7	33	duel warden	127.09	#191919	2597
8	48	rock Renly in	21.53	#9e9e9e	2597
9	23	riverlands north	169.96	#545454	2593

Tabla exportada en formato CSV y con sus datos formateados y ranqueados.

product_id	name	price	colour	total_sold
52	riverlands the duel	31.52	#727272	2654
29	Tully maester Taryl	167.2	#111111	2635
21	duel Direwolf	96.9	#e2e2e2	2609
16	the duel warden	180.91	#666666	2608
66	mustafar jinn	2.12	#545454	2601
87	sith Jade	96.26	#e2e2e2	2598
33	duel warden	127.09	#191919	2597
48	rock Renly in	21.53	#9e9e9e	2597
23	riverlands north	169.96	#545454	2593
68	Stark Karstark	167.37	#333333	2589
88	Stannis warden south	167.15	#515151	2587
28	chewbacca mustafar	127.44	#efefef	2584
73	Dorne bastard	114.09	#848484	2584
4	warden south duel	71.89	#111111	2584
31	Lannister	85.02	#3f3f3f	2580
34	of north	128.48	#919191	2580
38	ewok sith	55.43	#666666	2578
54	dooku solo	13.14	#e5e5e5	2575
36	Lannister	96.22	#a5a5a5	2575
61	Winterfell Lannister	28.01	#848484	2575
24	south duel tourney	48.99	#aaaaaa	2574
11	Karstark Dorne	49.7	#141414	2573
72	north	161.6	#474747	2573
2	Taryl Stark	9.24	#919191	2573
10	Karstark Dorne	119.52	#f4f4f4	2571
47	Tully	82.15	#919191	2571
39	warden	196.65	#a0a0a0	2571
74	duel warden	158.29	#707070	2569
64	Direwolf	195.62	#b7b7b7	2568
65	riverlands the	121.91	#6b6b6b	2567
58	solo palpatine chewbacca	130.59	#2b2b2b	2567